

Chương 2

Kiến thức cơ sở

§1 Đánh giá tính chính xác của mô hình phân loại

Trong các phần trước, chúng ta đã nhắc tới một số độ đo dùng để đánh giá độ chính xác trong dự đoán của một mô hình: Accuracy; Precision và Recall. Để làm rõ hơn ý nghĩa của các đại lượng này, chúng ta sẽ xét chúng trong bài toán phân loại hai lớp (phân loại nhị phân - binary classification). Sau đó ta sẽ xét chúng trong các bài toán phân loại nhiều lớp (multi-class hoặc multinomial classification).

1.1 Binary classification

Với bài toán phân loại hai lớp, ta giả thiết hai phân loại dữ liệu sẽ là **positive** (+) và **negative** (-). Ta có ma trận nhầm lẫn - **Confusion matrix** như sau

		Predicted Class		
		Positive	Negative	
Actual Class	Positive	True Positive (TP)	False Negative (FN) Type II Error	Sensitivity $\frac{TP}{(TP + FN)}$
	Negative	False Positive (FP) Type I Error	True Negative (TN)	Specificity $\frac{TN}{(TN + FP)}$
		Precision $\frac{TP}{(TP + FP)}$	Negative Predictive Value $\frac{TN}{(TN + FN)}$	Accuracy $\frac{TP + TN}{(TP + TN + FP + FN)}$

Các chỉ số TP, FP, TN, FN lần lượt có ý nghĩa là :

- **TP (True Positive):** Tổng số trường hợp dự báo đúng Positive.
- **TN (True Negative):** Tổng số trường hợp dự báo đúng Negative.
- **FP (False Positive):** Tổng số trường hợp các quan sát (thực tế) thuộc nhãn Negative bị dự báo sai thành Positive.
- **FN (False Negative):** Tổng số trường hợp các quan sát (thực tế) thuộc nhãn Positive bị dự báo sai thành Negative.


1.1.1 Accuracy

Đại lượng Độ chính xác - Accuracy đo tỷ lệ số mẫu được mô hình dự đoán đúng trên tổng số mẫu dữ liệu được dùng để kiểm tra mô hình.

$$\text{Accuracy} = \frac{TP + TN}{\text{total sample}}$$

Giả sử một mô hình có độ chính xác $\text{accuracy} = 90\%$ có nghĩa là trong số 100 mẫu thì có 90 mẫu được phân loại đúng. Nhược điểm của độ đo này là đối với tập dữ liệu kiểm thử không cân bằng (nghĩa là số positive lớn hơn rất nhiều so với negative hoặc ngược lại) thì đánh giá có thể gây hiểu nhầm (xem lại bài giảng lý thuyết).

Một cách trực quan, accuracy là tỷ lệ số điểm dữ liệu trong hình tròn trên tổng số điểm dữ liệu trong hình vuông như trong minh họa dưới đây.



Trong Python, có thể sử dụng thư viện scikit learning sklearn để tính toán độ chính xác Accuracy. Giả sử y_label là nhãn đúng của dữ liệu và y_pred là nhãn dự báo theo mô hình, đoạn mã lệnh tính accuracy như sau:

```
## Python code with sklearn to calculate accuracy
## y_true : true label, y_pred: predict label
from sklearn.metrics import accuracy_score
accuracy_score(y_true, y_pred)
```

1.1.2 Precision

Với bài toán phân loại mà tập dữ liệu của các lớp chênh lệch nhau rất nhiều (mất cân bằng), thường sử dụng phương pháp đánh giá Precision-Recall. **Precision** được định nghĩa là tỉ lệ số mẫu true positive trong số những mẫu được phân loại là positive ($TP + FP$), tức là số mẫu được dự đoán (+) đúng, trên tổng số mẫu được dự đoán (+). Với precision = 0,9 có nghĩa là mô hình dự đoán đúng 90 mẫu trong 100 mẫu mà mô hình đã dự đoán là positive. Công thức của precision như sau

$$\text{Precision} = \frac{TP}{\text{total predicted positive}} = \frac{TP}{TP + FP}.$$

Precision trả lời cho câu hỏi trong các trường hợp được dự báo là positive thì có bao nhiêu trường hợp là đúng? Và tất nhiên precision càng cao thì mô hình của chúng ta càng tốt trong việc **dự đoán các mẫu là positive**.

1.1.3 Recall

Recall đo lường tỷ lệ dự báo chính xác các trường hợp positive trên toàn bộ các mẫu thực sự thuộc nhóm positive (tỷ lệ đoán (+) đúng trên số mẫu (+) thực tế). Công thức của recall như sau:

$$\text{Recall} = \frac{TP}{\text{total actual positive}} = \frac{TP}{TP + FN}.$$


Để tính được recall thì chúng ta phải biết trước nhãn (phân loại) thực sự của dữ liệu. Do đó recall có thể được dùng để đánh giá trên tập train và validation vì chúng ta đã biết trước nhãn.

Trên tập test khi dữ liệu được coi như mới hoàn toàn và chưa biết nhãn thì chúng ta sẽ sử dụng precision.

Ý nghĩa của các độ đo trên như sau: Precision cao đồng nghĩa độ chính xác của các mẫu đúng positive là cao. Recall cao đồng nghĩa với việc bỏ sót các mẫu thực sự positive là

thấp. Một mô hình phân lớp tốt là mô hình có cả Precision và Recall đều cao, tức càng gần một càng tốt.

Có thể minh họa ý nghĩa trên như trong hình dưới đây



Trong thư viện sklearn của Python, có thể tính toán precision-recall dựa trên ground truth y_label và xác suất dự báo y_prob như sau

```
## Python code with sklearn to calculate accuracy
## y_label : true label, y_prob: predict probabilities
from sklearn.metrics import precision_recall_curve
prec, rec, thres = precision_recall_curve(y_label, y_prob)
```

Chúng ta cũng có thể dựa theo công thức để tính toán trực tiếp các đại lượng này.

1.2 Multiclass|Multinomial classification

1.2.1 Accuracy

Nhớ rằng, accuracy là tỉ lệ phân loại đúng với tổng số mẫu, tức là tỷ lệ số lượng nằm trên nằm trên đường chéo của ma trận confusion so với tổng các phần tử trong ma trận đó. Để có accuracy, lấy tổng số lượng phân loại đúng chia với tổng số mẫu.

Vậy đại lượng này được tính một cách tương tự trong trường hợp nhiều lớp.

$$\text{Accuracy} = \frac{\sum_{c=1}^C \text{true in class}_c}{\text{total sample}}.$$

1.2.2 Precision-Recall

Chú ý precision-recall curve ban đầu được định nghĩa cho bài toán phân lớp nhị phân. Để có thể áp dụng các phép đo này cho bài toán multi-class classification, các đại lượng đầu ra (ground truth và predicted output) cần được đưa về dạng nhị phân.

Một cách tự nhiên nhất, ta có thể đưa bài toán phân lớp nhiều lớp về bài toán phân lớp nhị phân bằng cách xem xét riêng cho từng lớp. Với mỗi lớp, ta coi dữ liệu thuộc lớp đó có label là positive, tất cả các dữ liệu còn lại có label là negative (tức là không thuộc lớp positive). Sau đó, giá trị Precision, Recall, và PR curve được áp dụng lên từng lớp.

Với mỗi lớp, ta sẽ nhận được một cặp giá trị precision và recall. Với các bài toán có ít lớp dữ liệu, ta có thể minh họa PR curve cho từng lớp trên cùng một đồ thị.

Precision

Trước hết ta gọi TruePositives_c là số mẫu được phân loại đúng vào lớp c , tức là mẫu thực sự thuộc về lớp c và cũng được dự đoán thuộc lớp c . Ngược lại, FalsePositives_c là số mẫu được dự đoán là loại c nhưng thực tế không đúng như vậy. Lúc đó ta tính **Precision cho lớp c** như sau:

$$\text{Precision}_c = \frac{\text{TruePositives}_c}{\text{TruePositives}_c + \text{FalsePositives}_c}.$$

Một số tài liệu và thư viện mở rộng khái niệm Precision cho mô hình (toàn bộ các lớp) như sau:

$$\text{Precision} = \frac{\left\{ \sum_{c=1}^C (\text{Precision}_c) \right\}}{C}.$$

Recall

Tương tự khái niệm Precision cho trường hợp nhiều lớp, chúng ta mở rộng cho khái niệm Recall. Trước hết ta đặt FalseNegative_c là số mẫu thực tế thuộc lớp c nhưng bị mô hình dự đoán là không thuộc lớp c . Lúc đó công thức tính Recall cho lớp c là

$$\text{Recall}_c = \frac{\text{TruePositives}_c}{\text{TruePositives}_c + \text{FalseNegative}_c}.$$

Sau đó, người ta cũng có thể mở rộng khái niệm này cho Recall của mô hình (toàn bộ các lớp) bằng cách lấy trung bình

$$\text{Recall} = \frac{\left\{ \sum_{c=1}^C (\text{Recall}_c) \right\}}{C}.$$

Để rõ hơn các khái niệm trên trong trường hợp phân loại nhiều lớp, chúng ta xét ví dụ với số liệu được cho trong hình sau

		Predicted Classes			
		a	b	c	d
Actual Classes	a	50	3	0	0
	b	26	8	0	1
	c	20	2	4	0
	d	12	0	0	1

Để thấy tổng số mẫu là 127. Ta tính các đại lượng như sau

$$\text{Accuracy} = \frac{\sum_{c=1}^C \text{true in class}_c}{\text{total sample}} = \frac{50 + 8 + 4 + 1}{127}.$$

Precision cho từng lớp:

- Lớp a: $\text{Precision}_a = \frac{\text{TruePositives}_a}{\text{TruePositives}_a + \text{FalsePositives}_a} = \frac{50}{50 + (26 + 20 + 12)} = \frac{50}{108}.$
- Lớp b: $\text{Precision}_b = \frac{\text{TruePositives}_b}{\text{TruePositives}_b + \text{FalsePositives}_b} = \frac{8}{8 + (3 + 2 + 0)} = \frac{8}{13}.$
- Lớp c: $\text{Precision}_c = \frac{\text{TruePositives}_c}{\text{TruePositives}_c + \text{FalsePositives}_c} = \frac{4}{4 + (0 + 0 + 0)} = \frac{4}{4}.$
- Lớp d: $\text{Precision}_d = \frac{\text{TruePositives}_d}{\text{TruePositives}_d + \text{FalsePositives}_d} = \frac{1}{1 + (1 + 1 + 0)} = \frac{1}{2}.$

Recall cho từng lớp:

- Lớp a: $\text{Recall}_a = \frac{\text{TruePositives}_a}{\text{TruePositives}_a + \text{FalseNegatives}_a} = \frac{50}{50 + (3 + 0 + 0)} = \frac{50}{53}.$
- Lớp b: $\text{Recall}_b = \frac{\text{TruePositives}_b}{\text{TruePositives}_b + \text{FalseNegatives}_b} = \frac{8}{8 + (26 + 0 + 1)} = \frac{8}{35}.$
- Lớp c: $\text{Recall}_c = \frac{\text{TruePositives}_c}{\text{TruePositives}_c + \text{FalseNegatives}_c} = \frac{4}{4 + (20 + 2 + 4)} = \frac{4}{26}.$
- Lớp d: $\text{Recall}_d = \frac{\text{TruePositives}_d}{\text{TruePositives}_d + \text{FalseNegatives}_d} = \frac{1}{1 + (12 + 1 + 0)} = \frac{1}{14}.$