

Support Vector Machine: Multi Classes

Machine Learning

Informatics Dep. MIM, HUS, VNU

2025

- Từ SVM nhị phân $\Rightarrow$ SVM đa lớp (multiclass) theo mô hình Crammer–Singer.
- Thiết lập bài toán tối ưu (primal):
 - Hàm mục tiêu $\frac{1}{2} \sum_k \|w_k\|^2 + C \sum_n \xi_n$.
 - Các ràng buộc margin đa lớp.
- Xây dựng Lagrangian, rút ra bài toán dual và điều kiện KKT đầy đủ.
- Ví dụ minh họa toy (3 lớp trong $\mathbb{R}^2$) + hình minh họa margin đa lớp.

- Dữ liệu huấn luyện:

$$(x_n, y_n), \quad n = 1, \dots, N, \quad x_n \in \mathbb{R}^d, \quad y_n \in \{1, \dots, K\}.$$

- Mỗi lớp k gắn với một vector trọng số:

$$w_k \in \mathbb{R}^d, \quad f_k(x) = w_k^\top x.$$


- Dự đoán:

$$\hat{y}(x) = \arg \max_{k \in \{1, \dots, K\}} f_k(x) = \arg \max_k w_k^\top x.$$

- Ý tưởng margin đa lớp:

Điểm số lớp đúng phải lớn hơn điểm số mọi lớp sai $\Rightarrow$ “thắng” với biên ít nhất 1.

1-vs-rest



- Dữ liệu: (x_n, y_n) , $y_n \in \{-1, +1\}$.
- Mô hình tuyến tính:

$$f(x) = w^\top x + b, \quad \hat{y} = \text{sign}(f(x)).$$

- Nếu dữ liệu phân tách tuyến tính, tồn tại (w, b) sao cho:

$$y_n(w^\top x_n + b) > 0, \quad \forall n.$$

- Nhưng: nếu (w, b) là nghiệm, thì $(\lambda w, \lambda b)$ với $\lambda > 0$ cũng là nghiệm.
- Cần tiêu chí chọn nghiệm “tốt nhất” $\Rightarrow$ **max-margin**.

- Margin hình học cho mẫu x_n :

$$\gamma_n = \frac{y_n(w^\top x_n + b)}{\|w\|}.$$

- Chuẩn hoá bằng ràng buộc

$$y_n(w^\top x_n + b) \geq 1, \quad \forall n$$

thì margin nhỏ nhất:

$$\gamma = \min_n \frac{y_n(w^\top x_n + b)}{\|w\|} = \frac{1}{\|w\|}.$$

- Maximize margin $\gamma \iff$ minimize $\|w\|$.
- Viết thành bài toán:

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad \text{s.t. } y_n(w^\top x_n + b) \geq 1, \forall n.$$

- Hệ số $\frac{1}{2}$:
 - Không làm thay đổi nghiệm tối ưu.
 - Giúp đạo hàm gọn: $\nabla_w \frac{1}{2} \|w\|^2 = w$.

- Thêm **slack** để cho phép vi phạm margin:

$$\min_{w,b,\xi} \frac{1}{2} \|w\|^2 + C \sum_{n=1}^N \xi_n$$

$$\text{s.t. } y_n(w^\top x_n + b) \geq 1 - \xi_n, \quad \xi_n \geq 0.$$

- Diễn giải:
 - $\frac{1}{2} \|w\|^2 \rightarrow$ phạt mô hình “phức tạp”, khuyến khích margin lớn.
 - $C \sum \xi_n \rightarrow$ phạt các vi phạm margin (lỗi / outlier).
- Đây là khuôn mẫu:

Độ phức tạp mô hình + Lỗi huấn luyện (có phạt).

- Với K lớp, cách mở rộng tự nhiên nhất:
 - Huấn luyện K bộ phân loại SVM nhị phân.
 - Mỗi lớp k đối đầu với “phần còn lại”.


- Mô hình:

$$f_k(x) = w_k^\top x.$$

- Dự đoán:

$$\hat{y}(x) = \arg \max_k f_k(x).$$

- Mỗi classifier được huấn luyện độc lập như một bài toán nhị phân.



Với mỗi điểm x_n và mỗi lớp k , định nghĩa:

$$\tilde{y}_{n,k} = \begin{cases} +1 & \text{nếu } y_n = k, \\ -1 & \text{nếu } y_n \neq k. \end{cases}$$

Ràng buộc soft-margin:

$$\tilde{y}_{n,k}(w_k^\top x_n) \geq 1 - \xi_{n,k}, \quad \xi_{n,k} \geq 0.$$

Hàm mục tiêu:

$$\min \frac{1}{2} \sum_{k=1}^K \|w_k\|^2 + C \sum_{n=1}^N \sum_{k=1}^K \xi_{n,k}.$$

- Mỗi điểm có K **slack variables**.
- Một điểm có thể bị phạt nhiều lần.

- Một điểm dữ liệu có thể:
 - Vi phạm nhẹ nhiều classifier.
 - Nhưng tổng phạt $\sum_k \xi_{n,k}$ vẫn lớn.

- OvR không ép trực tiếp:

$$w_{y_n}^\top x_n \geq w_k^\top x_n.$$

- Không tồn tại margin “so sánh” giữa các lớp.
- Các biên được học độc lập $\Rightarrow$ thiếu tính toàn cục.

Ý tưởng tinh gọn từ OvR:

- Với mỗi điểm x_n , chỉ lớp sai **nguy hiểm nhất** là quan trọng.
- Gộp $\{\xi_{n,k}\}$ thành **một** slack ξ_n :


$$\xi_n = \max_{k \neq y_n} (1 + w_k^\top x_n - w_{y_n}^\top x_n)_+.$$

- Ràng buộc margin mới:

$$w_{y_n}^\top x_n \geq w_k^\top x_n + 1 - \xi_n.$$

Crammer–Singer là:

- OvR đã được "chuẩn hoá" về mặt hình học.
- Margin đa lớp rõ ràng, toàn cục và nhất quán.



Main idea:

Crammer–Singer có thể xem là OvR được *chuẩn hoá về mặt hình học và margin*, còn hinge loss là dạng *unconstrained* của cùng một ý tưởng tối ưu.

- Đa lớp: mỗi lớp k có vector w_k , điểm số:

$$f_k(x) = w_k^\top x.$$

- Với mẫu (x_n, y_n) :

- Điểm số lớp đúng: $f_{y_n}(x_n) = w_{y_n}^\top x_n$.
- Điểm số lớp sai: $f_k(x_n) = w_k^\top x_n, k \neq y_n$.

- Margin đa lớp theo Crammer–Singer cho mẫu n :


$$\text{margin}_n = \min_{k \neq y_n} (w_{y_n}^\top x_n - w_k^\top x_n).$$

- Ràng buộc **hard margin**:

$$w_{y_n}^\top x_n \geq w_k^\top x_n + 1, \quad \forall k \neq y_n.$$

- Thêm slack:

$$w_{y_n}^\top x_n \geq w_k^\top x_n + 1 - \xi_n, \quad \forall k \neq y_n.$$



Vì sao $\frac{1}{2} \sum_k \|w_k\|^2$ trong đa lớp?

- Gom các vector lớp thành ma trận:

$$W = [w_1, \dots, w_K] \in \mathbb{R}^{d \times K}.$$

- “Độ phức tạp” của mô hình đa lớp: dùng chuẩn Frobenius

$$\|W\|_F^2 = \sum_{k=1}^K \|w_k\|^2.$$

- Lý do tự nhiên:
 - Các lớp đối xứng, không lớp nào “đặc biệt” hơn.
 - Biên giữa lớp y_n và lớp k phụ thuộc vào hiệu $(w_{y_n} - w_k)$.
 - Nếu mọi $\|w_k\|$ đều nhỏ, thì các hiệu $w_{y_n} - w_k$ cũng “vừa phải” $\Rightarrow$ không có biên nào quá “lỗ”.
- Chọn hàm phạt độ phức tạp (mở rộng Margin):

$$\Omega(W) = \frac{1}{2} \sum_{k=1}^K \|w_k\|^2.$$

- **Loss đa lớp** (hinge):

$$\ell_n(W) = \max_{k \neq y_n} (1 + w_k^\top x_n - w_{y_n}^\top x_n)_+.$$

- **Regularizer** (kiểm soát độ phức tạp):

$$\Omega(W) = \frac{1}{2} \sum_{k=1}^K \|w_k\|^2.$$

- Bài toán ERM:

$$\min_W \lambda \Omega(W) + \frac{1}{n} \sum_{n=1}^N \ell_n(W).$$

- Dạng ràng buộc (với slack ξ_n):

$$\min_{W, \xi} \frac{1}{2} \sum_{k=1}^K \|w_k\|^2 + C \sum_{n=1}^N \xi_n$$

$$\text{s.t. } w_{y_n}^\top x_n - w_k^\top x_n \geq 1 - \xi_n, \quad \forall n, k \neq y_n, \quad \xi_n \geq 0.$$

- Cùng một tinh thần: **biên lớn + lỗi nhỏ**, được tổng quát từ SVM nhị phân.

Ràng buộc margin đa lớp

Với mỗi mẫu (x_n, y_n) và mọi lớp $k \neq y_n$:

$$w_{y_n}^\top x_n \geq w_k^\top x_n + 1 - \xi_n.$$

Bài toán primal (Crammer–Singer)

$$\begin{aligned} \min_{W, \xi} \quad & \frac{1}{2} \sum_{k=1}^K \|w_k\|^2 + C \sum_{n=1}^N \xi_n \\ \text{s.t.} \quad & w_{y_n}^\top x_n - w_k^\top x_n \geq 1 - \xi_n, \quad \forall n, \forall k \neq y_n, \\ & \xi_n \geq 0, \quad \forall n. \end{aligned}$$

Trong đó $W = [w_1, \dots, w_K]$ và $C > 0$ là tham số phạt.

(C1) Ràng buộc margin đa lớp

$$w_{y_n}^\top x_n - w_k^\top x_n \geq 1 - \xi_n, \quad \forall n, \forall k \neq y_n.$$

(C2) Ràng buộc không âm của slack

$$\xi_n \geq 0, \quad \forall n.$$

Các ràng buộc này sẽ được gắn với các nhân tử Lagrange:

- $\alpha_{n,k} \geq 0$ tương ứng với (C1).
- $\beta_n \geq 0$ tương ứng với (C2).

Ta xây dựng Lagrangian:

$$\begin{aligned}\mathcal{L}(W, \xi, \alpha, \beta) = & \frac{1}{2} \sum_{k=1}^K \|w_k\|^2 + C \sum_{n=1}^N \xi_n \\ & - \sum_{n=1}^N \sum_{k \neq y_n} \alpha_{n,k} \left(w_{y_n}^\top x_n - w_k^\top x_n - 1 + \xi_n \right) \\ & - \sum_{n=1}^N \beta_n \xi_n,\end{aligned}$$

với

$$\alpha_{n,k} \geq 0, \quad \forall n, k \neq y_n; \quad \beta_n \geq 0, \quad \forall n.$$

Mục tiêu:

- Tối thiểu theo W, ξ .
- Tối đa theo α, β (dual).

Điều kiện KKT cho bài toán lỗi:

- **(P) Primal feasibility:**

$$\begin{aligned}w_{y_n}^\top x_n - w_k^\top x_n &\geq 1 - \xi_n, \quad \forall n, \forall k \neq y_n, \\ \xi_n &\geq 0, \quad \forall n.\end{aligned}$$

- **(D) Dual feasibility:**

$$\alpha_{n,k} \geq 0, \quad \forall n, k \neq y_n; \quad \beta_n \geq 0, \quad \forall n.$$

- **(S) Stationarity:** đạo hàm $\mathcal{L}$ theo w_k và ξ_n bằng 0.

- **(CS) Complementary slackness:**

$$\begin{aligned}\alpha_{n,k} \left(w_{y_n}^\top x_n - w_k^\top x_n - 1 + \xi_n \right) &= 0, \\ \beta_n \xi_n &= 0, \quad \forall n, k \neq y_n.\end{aligned}$$

Xét đạo hàm của $\mathcal{L}$ theo w_k :

$$\frac{\partial}{\partial w_k} \left(\frac{1}{2} \sum_{l=1}^K \|w_l\|^2 \right) = w_k.$$

Với mỗi n :

- Nếu $y_n = k$, hạng tử liên quan là $-\sum_{l \neq k} \alpha_{n,l} (w_k^\top x_n - w_l^\top x_n - 1 + \xi_n)$
 $\Rightarrow$ đạo hàm theo w_k : $-\sum_{l \neq k} \alpha_{n,l} x_n$.
- Nếu $y_n \neq k$, hạng tử liên quan là $-\alpha_{n,k} (w_{y_n}^\top x_n - w_k^\top x_n - 1 + \xi_n)$
 $\Rightarrow$ đạo hàm theo w_k : $+\alpha_{n,k} x_n$.

Do đó điều kiện stationarity:

$$\frac{\partial \mathcal{L}}{\partial w_k} = w_k - \sum_{n: y_n = k} \sum_{l \neq k} \alpha_{n,l} x_n + \sum_{n: y_n \neq k} \alpha_{n,k} x_n = 0.$$

Từ điều kiện stationarity:

$$w_k = \sum_{n:y_n=k} \sum_{l \neq k} \alpha_{n,l} x_n - \sum_{n:y_n \neq k} \alpha_{n,k} x_n.$$

Đây là biểu diễn trọng số w_k theo các nhân tử Lagrange $\alpha_{n,k}$:

- Tương tự SVM nhị phân, nhưng phức tạp hơn do nhiều lớp.
- Cho thấy w_k là tổ hợp tuyến tính của các điểm dữ liệu (các “support vectors” đa lớp).

Đạo hàm theo ξ_n :

$$\frac{\partial \mathcal{L}}{\partial \xi_n} = C - \sum_{k \neq y_n} \alpha_{n,k} - \beta_n = 0.$$

Suy ra:

$$\beta_n = C - \sum_{k \neq y_n} \alpha_{n,k}.$$

Kết hợp với điều kiện dual feasibility $\beta_n \geq 0$:

$$\sum_{k \neq y_n} \alpha_{n,k} \leq C.$$

Đây là ràng buộc quan trọng trong bài toán dual.

Thay w_k và ξ_n đã triệt tiêu vào Lagrangian, ta thu được bài toán dual:

Dual Crammer–Singer

$$\begin{aligned} \max_{\alpha} \quad & \sum_{n=1}^N \sum_{k \neq y_n} \alpha_{n,k} - \frac{1}{2} \sum_{k=1}^K \left\| \sum_{n: y_n = k} \sum_{l \neq k} \alpha_{n,l} X_n - \sum_{n: y_n \neq k} \alpha_{n,k} X_n \right\|^2 \\ \text{s.t.} \quad & \sum_{k \neq y_n} \alpha_{n,k} \leq C, \quad \alpha_{n,k} \geq 0, \quad \forall n, k \neq y_n. \end{aligned}$$

Đây là bài toán QP lồi trong không gian biến dual α .

Từ các ràng buộc margin, ta có thể viết lại dạng hinge loss đa lớp:

$$\ell_n(W) = \max_{k \neq y_n} (1 + w_k^\top x_n - w_{y_n}^\top x_n)_+,$$

với $(z)_+ = \max(0, z)$.

Bài toán tối ưu dạng regularized risk

$$\min_W \frac{\lambda}{2} \sum_{k=1}^K \|w_k\|^2 + \frac{1}{n} \sum_{n=1}^N \ell_n(W).$$

- Đây là cách tiếp cận “primal + hinge loss”: không viết ràng buộc rõ ràng.
- Có thể giải bằng (sub)gradient descent, SGD, thích hợp cho dữ liệu lớn.

Ý tưởng: loại bỏ ξ_n để ra hinge loss (1/3)

Bài toán primal:

$$\min_{W, \xi} \frac{1}{2} \sum_{k=1}^K \|w_k\|^2 + C \sum_{n=1}^N \xi_n$$

$$\text{s.t. } w_{y_n}^\top x_n - w_k^\top x_n \geq 1 - \xi_n, \quad \forall k \neq y_n; \quad \xi_n \geq 0.$$

Ý tưởng:

- Với một W cố định, ξ_n chỉ xuất hiện trong:

$$C\xi_n \quad \text{và} \quad w_{y_n}^\top x_n - w_k^\top x_n \geq 1 - \xi_n.$$

- Ta có thể tìm ξ_n **nhỏ nhất có thể** để thỏa ràng buộc, vì mục tiêu đang **tăng** theo ξ_n .
- Khi tìm được $\xi_n^*(W)$ theo W , thay ngược lại vào hàm mục tiêu $\Rightarrow$ thu được dạng **unconstrained** chỉ còn W .

Ý tưởng: loại bỏ ξ_n để ra hinge loss (2/3)

Xét riêng một mẫu (x_n, y_n) , với W cố định.

- Ràng buộc (C1) viết lại:

$$\xi_n \geq 1 + w_k^\top x_n - w_{y_n}^\top x_n, \quad \forall k \neq y_n.$$

- Ràng buộc (C2):

$$\xi_n \geq 0.$$

- Kết hợp tất cả:

$$\xi_n \geq 0, \quad \xi_n \geq 1 + w_k^\top x_n - w_{y_n}^\top x_n, \quad \forall k \neq y_n.$$

- Do hàm mục tiêu chứa $C\xi_n$ (tăng theo ξ_n), **giá trị tối ưu** sẽ là:

$$\xi_n^*(W) = \max \left(0, \max_{k \neq y_n} (1 + w_k^\top x_n - w_{y_n}^\top x_n) \right).$$

Ý tưởng: loại bỏ ξ_n để ra hinge loss (3/3)

Đặt:

$$\ell_n(W) = \max_{k \neq y_n} (1 + w_k^\top x_n - w_{y_n}^\top x_n)_+,$$

trong đó $(z)_+ = \max(0, z)$.

- Từ slide trước: $\xi_n^*(W) = \ell_n(W)$.
- Thay ngược lại vào hàm mục tiêu:

$$\min_W \frac{1}{2} \sum_{k=1}^K \|w_k\|^2 + C \sum_{n=1}^N \xi_n^*(W) = \min_W \frac{1}{2} \sum_{k=1}^K \|w_k\|^2 + C \sum_{n=1}^N \ell_n(W).$$

- Đây chính là dạng **unconstrained** theo W với **multiclass hinge loss**.

Kết luận:

$$\ell_n(W) = \max_{k \neq y_n} (1 + w_k^\top x_n - w_{y_n}^\top x_n)_+$$

là hàm mất mát “ẩn” bên trong các ràng buộc và slack ξ_n .

Sau khi loại bỏ ξ_n :

$$\min_W \frac{1}{2} \sum_{k=1}^K \|w_k\|^2 + C \sum_{n=1}^N \ell_n(W),$$

trong đó

$$\ell_n(W) = \max_{k \neq y_n} (1 + w_k^\top x_n - w_{y_n}^\top x_n)_+.$$

Ta có thể chuẩn hoá lại:

$$\min_W \frac{\lambda}{2} \sum_{k=1}^K \|w_k\|^2 + \frac{1}{n} \sum_{n=1}^N \ell_n(W),$$

với λ liên hệ với C và n (ví dụ: $\lambda = \frac{1}{nC}$). **Ý nghĩa thực tế:**

- Đây là bài toán ERM quen thuộc: **Regularizer + Empirical loss**.
- Có thể giải bằng (sub)gradient descent, SGD, mini-batch, thích hợp với dữ liệu lớn.
- Dual/Lagrange vẫn quan trọng về mặt lý thuyết (đặc biệt khi dùng kernel).

Xét dữ liệu:

Điểm	$x = (x_1, x_2)$	Nhãn y
1	(1, 1)	1
2	(2, 1)	1
3	(1, 3)	2
4	(2, 4)	2
5	(4, 1)	3
6	(5, 2)	3

- Ba cụm điểm 1,2; 3,4; 5,6 tương ứng ba lớp 1,2,3.
- Trong thực tế, nghiệm w_k được tìm bằng solver QP.
- Để minh họa, ta chỉ cần:
 - Liệt kê ràng buộc margin (C1) cho từng điểm.
 - Vẽ sơ đồ phân bố điểm trong $\mathbb{R}^2$.

Lấy ví dụ với một vài ràng buộc (bỏ ξ_n để hiểu ý tưởng hard-margin):

- Điểm $(1, 1)$, $y_1 = 1$:

$$w_1^\top (1, 1) \geq w_2^\top (1, 1) + 1 - \xi_1,$$

$$w_1^\top (1, 1) \geq w_3^\top (1, 1) + 1 - \xi_1.$$

- Điểm $(1, 3)$, $y_3 = 2$:

$$w_2^\top (1, 3) \geq w_1^\top (1, 3) + 1 - \xi_3,$$

$$w_2^\top (1, 3) \geq w_3^\top (1, 3) + 1 - \xi_3.$$

- Điểm $(4, 1)$, $y_5 = 3$:

$$w_3^\top (4, 1) \geq w_1^\top (4, 1) + 1 - \xi_5,$$

$$w_3^\top (4, 1) \geq w_2^\top (4, 1) + 1 - \xi_5.$$

Tất cả các ràng buộc đều có dạng: $w_{y_n}^\top x_n \geq \max_{k \neq y_n} w_k^\top x_n + 1 - \xi_n$.

Bối cảnh phù hợp:

- Cần dùng **kernel phi tuyến** (RBF, polynomial, ...).
- Kích thước dữ liệu **vừa–nhỏ**:
 - Số mẫu n không quá lớn (vài nghìn đến vài chục nghìn).
 - Số chiều d có thể lớn, nhưng QP vẫn xử lý được.
- Muốn tận dụng các **solver QP** chuẩn, hoặc thư viện SVM kernel truyền thống (LIBSVM, ...).
- Cần phân tích **lý thuyết**:
 - Cấu trúc nghiệm theo các *support vectors*.
 - Ràng buộc KKT, điều kiện tối ưu, biên dạng dual.

Ưu điểm:

- Kernel trick “chuẩn”, biên quyết định rất linh hoạt.
- Khai thác đầy đủ tính lồi, có lời giải QP rõ ràng.

Bối cảnh phù hợp:

- Mô hình **tuyến tính** hoặc đã có **feature embedding sẵn** (từ deep network, word embeddings, ...).
- Dữ liệu **lớn**:
 - Số mẫu n rất lớn (hàng trăm nghìn, triệu).
 - Không thể giải QP “nguyên bản” vì chi phí $\mathcal{O}(n^2)$ hoặc hơn.
- Cần **huấn luyện online / mini-batch** trên stream dữ liệu.
- Dễ tích hợp vào **framework deep learning** (PyTorch, TensorFlow, ...):

$$\min_W \frac{\lambda}{2} \sum_k \|w_k\|^2 + \frac{1}{n} \sum_n \ell_{\text{hinge}}(x_n, y_n; W).$$

Ưu điểm:

- Tối ưu bằng (sub)gradient descent, SGD, Adam, dễ cài đặt.
- Rất phù hợp cho **large-scale learning** và pipeline “deep feature + linear SVM”.

- SVM đa lớp Crammer–Singer:
 - Primal: tối thiểu $\frac{1}{2} \sum_k \|w_k\|^2 + C \sum_n \xi_n$ với ràng buộc margin đa lớp.
 - Dual: bài toán QP trên các nhân tử Lagrange $\alpha_{n,k}$.
- Điều kiện KKT:
 - Primal feasibility (C1), (C2).
 - Dual feasibility, stationarity, complementary slackness.
- Hinge loss đa lớp là một cách viết lại primal dưới dạng “mất mát + regularizer”, thuận tiện cho tối ưu bằng SGD trên dữ liệu lớn.
- Ví dụ toy 3 lớp trong $\mathbb{R}^2$ giúp trực quan hoá margin đa lớp.