

MACHINE LEARNING

Cao Văn Chung
cvanchung@hus.edu.vn

Informatics Dept., MIM, HUS, VNU Hanoi

CLUSTERING

Latent variable Models

- Latent variable models

- Multi-Dimensional Gaussian distribution & its MLE

- Gaussian Mixture Model

- MLE for Gaussian Mixture Model

- Expectation-Maximization Algorithm (EM)

- k-means Algorithm

Density-Based Clustering



- Evaluation metrics of clustering algorithms

Latent variable - Mixture Models - KMeans

Latent variable models

Quan sát các tập dữ liệu dưới đây:

Hình (a) là tập dữ liệu phân bố thành 03 cụm - được gán nhãn (theo màu sắc đỏ - xanh - đen). Hình (b) vẫn là dữ liệu đó nhưng không có nhãn (tất cả cùng màu).



Latent variable models

► **Nhắc lại:**

- ▶ Trong các mô hình học máy có huấn luyện (supervised), training dataset với biến quan sát đầu vào $\mathbf{x}_n$ và biến đầu ra (nhãn hoặc giá trị) y_n , giống như hình (a) ở trên, mỗi nhóm dữ liệu được gán nhãn (ví dụ màu sắc) khác nhau.
- ▶ Trong lúc đó, với học không giám sát, ta chỉ có dữ liệu quan sát đầu vào $\mathbf{x}_n$ mà không có nhãn, như là tập dữ liệu testing dataset, giống như hình (b).
- ▶ Tuy nhiên, dữ liệu trong cả hai trường hợp thực tế đều phân bố vào các cụm.
- ▶ **Câu hỏi:** Nếu chỉ có tập dữ liệu thô (chưa gán nhãn) thì có cách nào xác định được dữ liệu thực sự phân bố thành các cụm như thế nào hay không? Giả thiết các cụm đó đều có phân bố chuẩn (Gaussian).


⇒ Phương pháp phân cụm dữ liệu - **Clustering**.

Multi-Dimensional Gaussian distribution

- Ta xét lại ví dụ tạo dữ liệu trong đoạn lệnh dưới đây (bài SVM - Hard Margin)

```
means = [[1, 2], [5, 1]]
cov = [[.5, .2], [.2, .5]]
N = 50
# create class 1
X0 = np.random.multivariate_normal(means[0], cov, N)
# create class -1
X1 = np.random.multivariate_normal(means[1], cov, N)
# rearrange all data
X = np.concatenate((X0.T, X1.T), axis = 1)
# labels
y = np.concatenate((np.ones((1, N)), -1*np.ones((1, N))), axis = 1)
```

Distribution Data from Code



Multi-Dimensional Gaussian distribution

Nhận xét

- ▶ Trong các ví dụ với dữ liệu nhân tạo ở phần trước, ta thường chọn tạo dữ liệu với phân phối Gauss (Gaussian distribution).
- ▶ Khi thực hiện cách tiếp cận ước lượng hợp lý cực đại để xác định tham số (MLE) ta cũng thường dựa vào giả thiết dữ liệu tuân theo phân bố chuẩn.
- ▶ Lý do?

MLE for Multi-Dimensional Gaussian distribution

- ▶ Xét bộ dữ liệu N quan sát độc lập $\mathbf{X} = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}$. Trong đó $\mathbf{x}_n \in \mathbb{R}^d$, $n = 1, 2, \dots, N$.
- ▶ Giả sử các $\mathbf{x}_n$, $n = 1, 2, \dots, N$ được lấy mẫu từ phân phối Gaussian đa chiều (d chiều).
- ▶ Ta cần ước lượng các tham số của các phân phối tác động lên $\mathbf{X}$ thông qua ước lượng hợp lý cực đại MLE.

MLE for Multi-Dimensional Gaussian distribution

- ▶ Giả thiết các điểm quan sát $\mathbf{x}_n$ là được lấy từ một mẫu ngẫu nhiên phân bố chuẩn $\mathbf{X} \sim \mathcal{N}(\mu, \sigma^2)$.
- ▶ Lúc đó hàm mật độ của điểm dữ liệu $\mathbf{x}_n$, cũng là ước lượng hợp lý của nó, sẽ là

$$f_{\mathbf{x}_n}(\mathbf{x}; \mu, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(\mathbf{x} - \mu)^2}{2\sigma^2}\right).$$

- ▶ Từ giả thiết N mẫu quan sát độc lập, ta có hàm ước lượng hợp lý cho toàn tập dữ liệu là

$$L(\mu, \Sigma | \mathbf{X}) = \prod_{n=1}^N f_{\mathbf{x}_n}(\mathbf{x}_n | \mu, \Sigma).$$

- ▶ Với ma trận vuông A , ký hiệu $|A| = \det(A)$ - định thức của A , ta sử dụng hàm log hợp lý cực đại:

MLE for Multi-Dimensional Gaussian distribution

$$\begin{aligned}l(\mu, \Sigma | \mathbf{X}) &= \log \left[\prod_{n=1}^N f_{\mathbf{x}_n}(\mathbf{x}_n | \mu, \Sigma) \right] \\&= \log \left[\prod_{n=1}^N \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp \left(-\frac{1}{2} (\mathbf{x}_n - \mu)^\top \Sigma^{-1} (\mathbf{x}_n - \mu) \right) \right] \\&= \sum_{n=1}^N \left(-\frac{d}{2} \log(2\pi) - \frac{1}{2} \log |\Sigma| - \frac{1}{2} (\mathbf{x}_n - \mu)^\top \Sigma^{-1} (\mathbf{x}_n - \mu) \right) \quad (1) \\&= -\frac{N}{2} \log |\Sigma| - \sum_{n=1}^N \frac{1}{2} (\mathbf{x}_n - \mu)^\top \Sigma^{-1} (\mathbf{x}_n - \mu) - \underbrace{\frac{Nd}{2} \log(2\pi)}_C \\&= -\frac{N}{2} \log |\Sigma| - \sum_{n=1}^N \frac{1}{2} (\mathbf{x}_n - \mu)^\top \Sigma^{-1} (\mathbf{x}_n - \mu) + C\end{aligned}$$

MLE for Multi-Dimensional Gaussian distribution

- ▶ Lấy đạo hàm $l(\mu, \Sigma | \mathbf{X})$ theo μ ta dùng công thức: $\frac{\partial \mathbf{w}^\top \mathbf{A} \mathbf{w}}{\partial \mathbf{w}} = 2\mathbf{A} \mathbf{w}$. Lúc đó đặt $\Sigma^{-1} = \mathbf{A}$ và $\mathbf{x}_i - \mu = \mathbf{w}$ ta có

$$\frac{\partial l(\mu, \Sigma | \mathbf{X})}{\partial \mu} = - \sum_{i=1}^N \Sigma^{-1} (\mathbf{x}_i - \mu) = \Sigma^{-1} (N\mu - \sum_{i=1}^N \mathbf{x}_i) = 0$$

- ▶ Do Σ tồn tại nên từ đẳng thức cuối ta suy ra tham số tối ưu thỏa mãn

$$N\hat{\mu} - \sum_{i=1}^N \mathbf{x}_i = 0 \Leftrightarrow \hat{\mu} = \frac{\sum_{i=1}^N \mathbf{x}_i}{N} \quad (2)$$

MLE for Multi-Dimensional Gaussian distribution

Lấy đạo hàm $l(\mu, \Sigma | \mathcal{N})$ theo Σ ta cần dùng các công thức sau

- ▶ Nếu các phép nhân ma trận thực hiện được thì

$$\text{trace}(\mathbf{ABC}) = \text{trace}(\mathbf{CAB}) = \text{trace}(\mathbf{BCA})$$

- ▶ Nếu $\mathbf{x}^\top \mathbf{A} \mathbf{x} \in \mathbb{R}$ - đại lượng vô hướng thì:

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \text{trace}(\mathbf{x}^\top \mathbf{A} \mathbf{x}) = \text{trace}(\mathbf{x}^\top \mathbf{x} \mathbf{A})$$

- ▶ Các đạo hàm: $\frac{\partial \text{trace}(\mathbf{AB})}{\partial \mathbf{A}} = \frac{\partial \text{trace}(\mathbf{BA})}{\partial \mathbf{A}} = \mathbf{B}^\top$ và $\frac{\partial \log(\mathbf{A})}{\partial \mathbf{A}} = \mathbf{A}^{-\top}$.

- ▶ Ký hiệu $|A| = \det(A)$ — định thức ma trận vuông A , thì $|\mathbf{A}| = \frac{1}{|\mathbf{A}^{-1}|}$.

MLE for Multi-Dimensional Gaussian distribution

- ▶ Áp dụng để lấy đạo hàm $l(\mu, \Sigma | \mathcal{N})$ theo Σ ta có

$$\begin{aligned} l(\mu, \Sigma | \mathcal{D}) &= C - \frac{N}{2} \log |\Sigma| - \frac{1}{2} \sum_{i=1}^N (\mathbf{x}_i - \mu)^\top \Sigma^{-1} (\mathbf{x}_i - \mu) \\ &= C + \frac{N}{2} \log |\Sigma^{-1}| - \frac{1}{2} \sum_{i=1}^N \text{trace} [(\mathbf{x}_i - \mu)^\top (\mathbf{x}_i - \mu) \Sigma^{-1}] \end{aligned}$$

Và do đó

$$\begin{aligned} \frac{\partial l(\mu, \Sigma | \mathcal{D})}{\partial \Sigma^{-1}} &= \frac{N}{2} \Sigma^\top - \frac{1}{2} \sum_{i=1}^N (\mathbf{x}_i - \mu)(\mathbf{x}_i - \mu)^\top \\ &= \frac{N}{2} \Sigma - \frac{1}{2} \sum_{i=1}^N (\mathbf{x}_i - \mu)(\mathbf{x}_i - \mu)^\top \end{aligned}$$

MLE for Multi-Dimensional Gaussian distribution

- ▶ Đẳng thức cuối suy ra từ tính đối xứng của Σ .
- ▶ Cho đạo hàm bằng 0, ta có tham số tối ưu

$$\frac{N}{2}\hat{\Sigma} - \frac{1}{2}\sum_{i=1}^N(\mathbf{x}_i - \mu)(\mathbf{x}_i - \mu)^\top = 0 \Leftrightarrow \hat{\Sigma} = \frac{\sum_{i=1}^N(\mathbf{x}_i - \mu)(\mathbf{x}_i - \mu)^\top}{N} \quad (3)$$

- ▶ Từ (2) và (3) ta thấy ước lượng tối ưu cho tham số: kỳ vọng chính là trung bình cộng mẫu và Σ chính là ma trận hiệp phương sai mẫu.

$$\begin{cases} \hat{\mu} &= \frac{\sum_{i=1}^N \mathbf{x}_i}{N} = \mathbb{E}(\mathbf{X}) \\ \hat{\Sigma} &= \frac{\sum_{i=1}^N (\mathbf{x}_i - \mu)(\mathbf{x}_i - \mu)^\top}{N} = \mathbb{C}\text{ov}(\mathbf{X}) \end{cases} \quad (4)$$

Mixture models


- ▶ Trong phần tính toán trên, ta đã ước lượng tham số tối ưu cho trường hợp toàn bộ tập dữ liệu tuân theo chỉ 01 phân bố Gaussian duy nhất.
- ▶ Thực tế, một dữ liệu tổng thể có thể tổng hợp từ nhiều quần thể dữ liệu nhỏ, trong đó mỗi quần thể dữ liệu chịu ảnh hưởng bởi một/một số quy luật thống kê riêng.
- ▶ Mô hình xác suất cho phép biểu thị sự hiện diện của các quần thể con trong một tổng thể, nhưng không bắt buộc phải xác định rõ mỗi dữ liệu quan sát thuộc về quần thể con nào gọi là **Mô hình trộn - Mô hình hỗn hợp - Mixture models**.
- ▶ Trong mô hình này, mỗi dữ liệu quan sát chịu tác động của một số phân phối xác suất.
- ▶ Phần tiếp theo ta sẽ áp dụng các dạng mô hình hỗn hợp để phân cụm dữ liệu - một phương pháp học máy không giám sát.

Gaussian Mixture Model

- ▶ Giả sử dữ liệu phân bố thành C cụm, dữ liệu trong mỗi một cụm lại có dạng phân phối Gaussian nhiều chiều.
 - ▶ Chú ý: Xác suất của mỗi điểm dữ liệu không chỉ phụ thuộc vào một phân phối Gaussian duy nhất mà chịu tác động kết hợp từ nhiều phân phối Gaussian khác nhau từ mỗi cụm.
- ⇒ Gọi là **Mô hình trộn Gaussian - Gaussian Mixture Model - GMM**.
- ▶ Mục tiêu của GMM là ước lượng tham số phù hợp nhất cho C cụm thông qua phương pháp ước lượng hợp lý cực đại MLE.
 - ▶ Giả thiết của mô hình:
 - ▶ Dữ liệu mỗi cụm tuân theo phân phối Gaussian d chiều với tập tham số $\{(\mu_c, \Sigma_c)\}_{c=1}^C$
 - ▶ Tồn tại ước lượng ngẫu nhiên $z_c = z_c(\mathbf{x})$: $z_c = 1$ nếu dữ liệu $\mathbf{x}$ thuộc cụm thứ c , ngược lại $z_c(\mathbf{x}) = 0$.

Gaussian Mixture Model

Hình (a) Phân bố hỗn hợp từ 03 phân phối Gaussian 01 chiều. Hình (b) Phân bố hỗn hợp từ 03 phân phối Gaussian 02 chiều.



Gaussian Mixture Model

- ▶ z_c được coi như là một biến ẩn (**latent variable**) - Ta không quan sát được giá trị của nó. Vậy GMM là mô hình biến ẩn.
- ▶ Xác suất $P(z_c = 1|\mathbf{x})$ giúp ta xác định tham số phân phối của mô hình Gaussian Mixture.
- ▶ Tập các z_c của mỗi cụm c tạo thành phân phối xác suất $(\pi_1, \pi_2, \dots, \pi_C)$, với $\pi_k = p(z_k = 1|\mathbf{x})$.
- ▶ Một xác suất hỗn hợp tác động lên một điểm dữ liệu $\mathbf{x}$ được tính theo công thức Bayes như sau:

$$\begin{aligned} p(\mathbf{x}) &= \sum_{c=1}^C p(z_c) p(\mathbf{x}|z_c) = \sum_{c=1}^C p(z_c = 1) p(\mathbf{x}|\mu_c, \Sigma_c) \\ &= \sum_{c=1}^C \pi_c p(\mathbf{x}|\mu_c, \Sigma_c) = \sum_{c=1}^C \pi_c N(\mathbf{x}|\mu_c, \Sigma_c) \end{aligned}$$

MLE for Gaussian Mixture Model

- ▶ Xác suất $p(\mathbf{x}|\mu_i, \Sigma_i)$ được tính từ phân phối Gaussian d chiều và cũng là đại lượng mục tiêu cần tham số hóa.
- ▶ Giả sử chúng có một tập dữ liệu $\mathbf{X} = \{\mathbf{x}_n\}_{n=1}^N$ tuân theo phân phối hỗn hợp trên. Tìm ước lượng hợp lý cực đại cho tham số θ sao cho mô hình GMM là phù hợp nhất.
- ▶ Nghiệm tối ưu θ^*

$$\theta^* = \arg \max_{\theta} p(\mathbf{X}|\theta) = \arg \max_{\theta} \prod_{n=1}^N p(\mathbf{x}_n|\theta)$$

- ▶ Việc giải trực tiếp phương trình đạo hàm bằng 0 cho hàm logarith $\log p(\mathbf{X}|\theta)$ như trường hợp chỉ có 01 cụm là bất khả thi!

EM Algorithm

Thực tế cần sử dụng thuật toán EM (**Expectation-Maximization**) để giải lặp tìm θ tối ưu. Các bước của thuật toán:

- ▶ Xuất phát từ θ^0 nào đó.
- ▶ Từ θ^t , $t > 0$ - Lặp lại quá trình tính toán ước lượng hợp lý để cập nhật θ^{t+1} .
- ▶ Mỗi bước lặp có 02 thao tác (02 bước huấn luyện)
 - ▶ **E-Step**: Ước lượng phân phối của biến ẩn z_c thể hiện phân phối xác suất của các cụm c tương ứng với dữ liệu và bộ tham số phân phối.
 - ▶ **M-Step**: Cực đại hoá phân phối xác suất đồng thời (*join distribution probability*) của dữ liệu $\mathbf{X}$ và biến ẩn $\mathbf{Z}$.

Do vậy thuật toán lặp này có tên gọi là EM - Expectation Maximization.

EM Algorithm

- Để cập nhật θ tại bước lặp $t > 0$, thay cho hàm ước lượng hợp lý, ta xét hàm tích lũy (*auxiliary*):

$$\begin{aligned} Q(\theta, \theta_t) &= \mathbb{E}_z(\log p(\mathbf{X}, \mathbf{Z}|\theta_t)) = \sum_z p(z|\mathbf{X}, \theta_t) \log p(\mathbf{X}, \mathbf{Z}|\theta) \\ &= \sum_z p(z|\mathbf{X}, \theta_t) \log [p(\mathbf{Z}|\mathbf{X}, \theta)p(\mathbf{X}|\theta)] \\ &= \sum_z p(z|\mathbf{X}, \theta_t) \log p(\mathbf{Z}|\mathbf{X}, \theta) + \underbrace{\left[\sum_z p(z|\mathbf{X}, \theta) \right]}_1 \log p(\mathbf{X}|\theta) \\ &= \sum_z p(z|\mathbf{X}, \theta_t) \log p(\mathbf{Z}|\mathbf{X}, \theta) + \log p(\mathbf{X}|\theta) \end{aligned}$$

EM Algorithm

- ▶ $Q(\theta, \theta_t)$ là kì vọng của logarithm xác suất chung của $\mathbf{X}$ và $\mathbf{Z}$ và bằng tổng (có trọng số) của $p(\mathbf{z}|\mathbf{X}, \theta_t)$ - xác suất tiên nghiệm trên từng cụm.
- ▶ Ta sẽ chỉ ra $Q(\theta, \theta_t)$ tăng kéo theo hàm ước lượng hợp lý tăng:

$$\begin{aligned} Q(\theta, \theta_t) - Q(\theta_t, \theta_t) &= \log p(\mathbf{X}|\theta) - \log p(\mathbf{X}|\theta_t) - \sum_{\mathbf{z}} p(\mathbf{z}|\mathbf{X}, \theta_t) \log \frac{p(\mathbf{Z}|\mathbf{X}, \theta)}{p(\mathbf{Z}|\mathbf{X}, \theta_t)} \\ &= \log p(\mathbf{X}|\theta) - \log p(\mathbf{X}|\theta_t) - \underbrace{\text{KL}(p(\mathbf{Z}|\mathbf{X}, \theta), p(\mathbf{Z}|\mathbf{X}, \theta_t))}_{\geq 0} \\ &\leq \log p(\mathbf{X}|\theta) - \log p(\mathbf{X}|\theta_t) \end{aligned}$$

do tính chất $\sum_{\mathbf{z}} p(\mathbf{z}|\mathbf{X}, \theta_t) \log \frac{p(\mathbf{Z}|\mathbf{X}, \theta)}{p(\mathbf{Z}|\mathbf{X}, \theta_t)}$ là khoảng cách Kullback - Leibler - Divergence giữa hai phân phối. Vậy $Q(\theta, \theta_t)$ tăng thì $\log p(\mathbf{X}|\theta)$ tăng.

EM Algorithm

- ▶ Xác suất xảy ra tại một điểm dữ liệu có thể được biểu diễn:

$$p(\mathbf{x}_n, \mathbf{z}|\theta) = \prod_{c=1}^C [p(\mathbf{x}_n, z_c|\theta)]^{z_c} = \prod_{c=1}^C [p(\mathbf{x}_n|z_c, \theta)p(z_c|\theta)]^{z_c} = \prod_{c=1}^C [p(\mathbf{x}_n|z_c, \theta)\pi_c]^{z_c}$$

- ▶ Hàm hợp lý của phân phối xác suất đồng thời của $\mathbf{X}$ và $\mathbf{Z}$ có thể được viết

$$\mathcal{L}(\mathbf{X}, \mathbf{Z}|\theta) = p(\mathbf{X}, \mathbf{Z}|\theta) = \prod_{n=1}^N \prod_{c=1}^C [p(\mathbf{x}_n, z_c|\theta)]^{z_c} = \prod_{n=1}^N \prod_{c=1}^C [p(\mathbf{x}_n|z_c, \theta)\pi_c]^{z_c}$$

- ▶ Do đó

$$\log[p(\mathbf{X}, \mathbf{Z})] = \sum_{n=1}^N \sum_{c=1}^C z_c \log p(\mathbf{x}_n|z_c, \theta) + z_c \log \pi_c$$

EM Algorithm

Ta suy ra

$$\begin{aligned} Q(\theta, \theta_t) &= \mathbb{E}_{\mathbf{z}} [\log p(\mathbf{X}, \mathbf{Z}) | \theta_t] \\ &= \mathbb{E}_{\mathbf{z}} \left[\sum_{n=1}^N \sum_{c=1}^C z_c \log p(\mathbf{x}_n | z_c, \theta) + z_c \log \pi_c | \theta_t \right] \\ &= \sum_{n=1}^N \sum_{c=1}^C \mathbb{E}_{\mathbf{z}} [z_c | \theta_t] \log p(\mathbf{x}_n | z_c, \theta) + \mathbb{E}_{\mathbf{z}} [z_c | \theta_t] \log \pi_c \\ &= \sum_{n=1}^N \sum_{c=1}^C p(z_c | \mathbf{x}_n, \theta_t) [\log p(\mathbf{x}_n | z_c, \theta) + \log \pi_c] = \dots \end{aligned}$$

EM Algorithm

$$Q(\theta, \theta_t) = \dots$$

$$\begin{aligned} &= \sum_{n=1}^N \sum_{c=1}^C p(z_c | \mathbf{x}_n, \theta_t) \left[\log \frac{\exp \left(-\frac{1}{2} (\mathbf{x}_n - \mu_c)^\top \Sigma_c^{-1} (\mathbf{x}_n - \mu_c) \right)}{(2\pi)^{d/2} |\Sigma_c|^{1/2}} + \log \pi_c \right] \\ &= \sum_{n=1}^N \sum_{c=1}^C p(z_c | \mathbf{x}_n, \theta_t) \left[-\frac{1}{2} \log |\Sigma_c| - \frac{1}{2} (\mathbf{x}_n - \mu_c)^\top \Sigma_c^{-1} (\mathbf{x}_n - \mu_c) \right. \\ &\quad \left. + \log \pi_c + \text{Const}_c \right] \end{aligned}$$

EM Algorithm

E-step:

$$\begin{aligned}\mathbb{E}_z(z_c|\mathbf{x}_n, \theta_t) &= 1 \times p(z_c = 1|\mathbf{x}_n, \theta_t) + 0 \times p(z_c = 0|\mathbf{x}_n, \theta_t) \\ &= p(z_c|\mathbf{x}_n, \theta_t) = \frac{p(z_c|\theta_t)p(\mathbf{x}_n|z_c, \theta_t)}{p(\mathbf{x}_c|\theta_t)} \\ &= \frac{\pi_c N(\mu_{ct}, \Sigma_{ct}|\mathbf{x}_n)}{\sum_{c=1}^C \pi_c N(\mu_{ct}, \Sigma_{ct}|\mathbf{x}_n)}\end{aligned}$$

- ▶ π_c chính là xác suất tiên nghiệm (posteriori probability) bằng với tỷ lệ các quan sát thuộc về cụm c ở vòng lặp thứ t - xem lại cách tính ở phần Naive Bayes.
- ▶ $N(\mu_{ct}, \Sigma_{ct}|\mathbf{x}_n)$ là xác suất $\mathbf{x}_n$ rơi vào cụm c theo công thức phân phối Gaussian.

EM Algorithm

M-step: Tính toán và cho đạo hàm $\frac{\partial Q(\theta, \theta_t)}{\partial \theta} = 0$, chú ý θ là bộ tham số $\{\pi_c, \mu_c, \Sigma_c\}_{c=1}^C$. Ta tính đạo hàm theo từng biến μ_c và Σ_c như phần trước:

$$\begin{aligned}\frac{\partial Q(\theta, \theta_t)}{\partial \mu_c} &= \frac{\partial}{\partial \mu_c} \sum_{n=1}^N \sum_{c=1}^C p(z_c | \mathbf{x}_n, \theta_t) \left[-\frac{1}{2} \log |\Sigma_c| - \frac{1}{2} (\mathbf{x}_n - \mu_c)^\top \Sigma_c^{-1} (\mathbf{x}_n - \mu_c) \right. \\ &\quad \left. + \log \pi_c + C_c \right] \\ &= \frac{\partial}{\partial \mu_c} p(z_c | \mathbf{x}_n, \theta_t) \left[\sum_{n=1}^N \Sigma_c^{-1} (\mu_c - \mathbf{x}_n) \right] \\ &= \frac{\partial}{\partial \mu_c} \Sigma_c^{-1} \left[\sum_{n=1}^N p(z_c | \mathbf{x}_n, \theta_t) (\mu_c - \mathbf{x}_n) \right] = 0\end{aligned}$$

EM Algorithm

M-step:

Giải phương trình $\frac{\partial Q(\theta, \theta_t)}{\partial \mu_c} = 0$ ta được nghiệm tối ưu

$$\mu_c^* = \frac{\sum_{n=1}^N p(z_c | \mathbf{x}_n, \theta_t) \mathbf{x}_n}{\sum_{n=1}^N p(z_c | \mathbf{x}_n, \theta_t)}.$$

Chú ý ở đây $p(z_c | \mathbf{x}_n, \theta_t)$ là xác suất để $\mathbf{x}_n$ rơi vào cụm c mà ta đã tính được trong bước E-step.

EM Algorithm

M-step:

Tiếp theo ta tính đạo hàm theo Σ_c và giải phương trình đạo hàm bằng 0:

$$\begin{aligned}\frac{\partial Q(\theta, \theta_t)}{\partial \Sigma_c^{-1}} &= \frac{\partial}{\partial \mu_c} \sum_{n=1}^N \sum_{c=1}^k p(z_c | \mathbf{x}_n, \theta_t) \left[-\frac{1}{2} \log |\Sigma_c| - \frac{1}{2} (\mathbf{x}_n - \mu_c)^\top \Sigma_c^{-1} (\mathbf{x}_n - \mu_c) \right. \\ &\quad \left. + \log \pi_c + \text{Const}_c \right] \\ &= \sum_{n=1}^N p(z_c | \mathbf{x}_n, \theta_t) \left[\frac{1}{2} \Sigma_c - \frac{1}{2} (\mathbf{x}_n - \mu_c)(\mathbf{x}_n - \mu_c)^\top \right] = 0\end{aligned}$$

Suy ra tham số Σ_c tối ưu

$$\Sigma_c^* = \frac{\sum_{n=1}^N p(z_c | \mathbf{x}_n, \theta_t) [(\mathbf{x}_n - \mu_c)(\mathbf{x}_n - \mu_c)^\top]}{\sum_{n=1}^N p(z_c | \mathbf{x}_n, \theta_t)}.$$

EM Algorithm

M-step:

Vậy tham số tối ưu ở mỗi cụm c sẽ được cập nhật tại bước thứ t theo công thức:

$$\mu_c^* = \frac{\sum_{n=1}^N p(z_c | \mathbf{x}_n, \theta_t) \mathbf{x}_n}{\sum_{n=1}^N p(z_c | \mathbf{x}_n, \theta_t)};$$

$$\Sigma_c^* = \frac{\sum_{n=1}^N p(z_c | \mathbf{x}_n, \theta_t) [(\mathbf{x}_n - \mu_c)(\mathbf{x}_n - \mu_c)^T]}{\sum_{n=1}^N p(z_c | \mathbf{x}_n, \theta_t)}.$$

EM Algorithm

M-step:

Tuy nhiên để tính toán cho bước tiếp theo $t + 1$, ta còn cần tính các xác suất π_c , $c = 1, 2, \dots, C$. Do có các ràng buộc trên π_c :

$$\pi_c \geq 0 \quad \forall c = 1, \dots, C \quad \text{và} \quad \sum_{c=1}^C \pi_c = 1$$

nên ta dùng phương pháp nhân tử Lagrange. Hàm Lagrange ứng với $Q(\theta, \theta_t)$ là:

$$J(\theta, \theta_t) = Q(\theta, \theta_t) + \lambda \left[1 - \sum_{c=1}^C \pi_c \right]$$

EM Algorithm

M-step:

Lấy đạo hàm và cho bằng 0 ta được

$$\frac{\partial J(\theta, \theta_t)}{\partial \pi_c} = \frac{\partial Q(\theta, \theta_t)}{\partial \pi_c} - \lambda = \frac{\sum_{n=1}^N p(z_c | \mathbf{x}_n, \theta_t)}{\pi_c} - \lambda = 0.$$

Đẳng thức cuối suy ra $\pi_c = \frac{\sum_{n=1}^N p(z_c | \mathbf{x}_n, \theta_t)}{\lambda}$, kết hợp với điều kiện $\sum_{c=1}^C \pi_c = 1$ ta được $\sum_{j=1}^k \pi_j = \frac{\sum_{i=1}^N \sum_{j=1}^k p(z_j | \mathbf{x}_i, \theta_t)}{\lambda} = \frac{N}{\lambda} = 1$ hay $\lambda = N$ và thu được tham số tối ưu:

$$\pi_c^* = \frac{\sum_{n=1}^N p(z_c | \mathbf{x}_n, \theta_t)}{N}.$$

Đến đây ta có đầy đủ các ước lượng để tính cho bước lặp tiếp theo $t + 1$.

k-means Algorithm

- ▶ Trong thuật toán EM ở trên, từ khởi tạo ban đầu cho C cụm dữ liệu, tại mỗi bước ta thực hiện các thao tác
 - ▶ Với C cụm được phân từ bước trước, tính kỳ vọng mẫu μ_c và phương sai mẫu Σ_c cho dữ liệu trong mỗi cụm c .
 - ▶ Xét từng điểm dữ liệu, tính xác suất để điểm đó thuộc về mỗi cụm $c \in [1..C]$. Từ đó xác định lại việc mỗi điểm dữ liệu thuộc về cụm nào và chuyển sang bước lặp tiếp theo.
- ▶ Giả sử dữ liệu thuộc một không gian metric, và giữa các điểm dữ liệu quan sát có một công thức khoảng cách (cụ thể ở đây ta chỉ xét khoảng cách Euclide);
- ▶ Nếu chúng ta xác định biến ẩn z tại mỗi bước dựa trên việc điểm dữ liệu gần với tâm cụm nào hơn $\Rightarrow$ Thuật toán trở nên đơn giản hơn.
- ▶ Dựa vào cách tiếp cận này, có thể xây dựng **Thuật toán k-means**.

k-means Algorithm

Thuật toán k-means - Optimization

- ▶ Cho tập dữ liệu $\mathbf{X} = \{\mathbf{x}_n\}_{n=1}^N$; $\mathbf{x}_n \in \mathbb{R}^d$ và số cụm cần phân chia $1 < k < N$.
- ▶ Đặt biến ẩn $y_{n,j} \in \{0, 1\}$: $y_{n,j} = 1$ nếu và chỉ nếu $\mathbf{x}_n$ thuộc về cụm thứ j . Ngược lại $y_{n,j} = 0$.
- ▶ Với mỗi $\mathbf{x}_n$, ta có: $\sum_{j=1}^K y_{nj} = 1$.
- ▶ Giả sử đã biết K "tâm cụm" (Centroids) là $M = \{\mathbf{m}_k\}$, $k = 1, 2, \dots, K$. Ta sử dụng lại cách tiếp cận của phương pháp *LDA*:
- ▶ Giả sử các điểm $\mathbf{x}_n$ được phân vào cụm thứ k , lúc đó tổng phương sai nội bộ **within-class variance** của cụm thứ k , cho mỗi $\mathbf{x}_n$, sẽ là

$$\sum_{\mathbf{x}_n \in \text{Cluster}_k} \|\mathbf{x}_n - \mathbf{m}_k\|_2^2 = \sum_{y_{n,k}=1} \|\mathbf{x}_n - \mathbf{m}_k\|_2^2.$$

k-means Algorithm

Thuật toán k-means - Optimization

- ▶ Tổng **within-class variance** trên tất cả các cụm:

$$\text{Loss} = L(Y, M) = \sum_{n=1}^N \sum_{j=1}^K y_{n,j} \|x_n - m_j\|_2^2.$$

- ▶ Ta cần tìm tham số tối ưu:

$$(Y^*, M^*) = \operatorname{argmin}_{Y, M} L(Y, M) = \operatorname{argmin}_{Y, M} \sum_{n=1}^N \sum_{j=1}^K y_{n,j} \|x_n - m_j\|_2^2.$$

với ràng buộc: $y_{n,j} \in \{0, 1\}$ và $\sum_{j=1}^K y_{n,j} = 1$.

k-means Algorithm

Thuật toán k-means - Optimization

- ▶ Giả sử đã có các tâm cụm hiện tại tại $\{m_c\}_{c=1}^K$.
- ▶ Do $y_{n,j} \in \{0, 1\}$ và $\sum_{j=1}^K y_{n,j} = 1$,

$$\sum_{n=1}^N \sum_{j=1}^K y_{n,j} \|x_n - m_j\|_2^2 \longrightarrow \min_{Y, M}$$

nếu và chỉ nếu

$$\begin{cases} y_{n,j} = 1 & \text{khi và chỉ khi } \|x_n - m_j\|_2^2 = \min_c \|x_n - m_c\|_2^2 \\ y_{n,j} = 0 & \text{tất cả trường hợp khác.} \end{cases}$$

k-means Algorithm

Thuật toán k-means - Optimization

Với một bộ $\{y_{n,j}\}_{n=1,j=1}^{N,K}$ đã cho, ta có

$$\sum_{n=1}^N \sum_{j=1}^K y_{n,j} \|x_n - m_j\|_2^2 =: J(Y, M) \longrightarrow \min_M$$

nếu và chỉ nếu

$$\nabla_M J(Y, M) = \nabla_M \sum_{n=1}^N \sum_{j=1}^K y_{n,j} \|x_n - m_j\|_2^2 = \sum_{n=1}^N \sum_{j=1}^K y_{n,j} \nabla_M \|x_n - m_j\|_2^2 = 0$$

k-means Algorithm

Thuật toán k-means - Optimization

Tức là $\frac{\partial J}{\partial m_j} = 0$ với mọi $j = 1, 2, \dots, K$

$$\sum_{n=1}^N y_{n,j} 2(x_n - m_j) = 2 \sum_{y_{n,j}=1} (x_n - m_j) = 2 \sum_{x_n \in \text{Cluster}_j} (x_n - m_j) = 0$$

Đặt $N_j = |\text{Cluster}_j|$, đẳng thức cuối suy ra

$$\sum_{x_n \in \text{Cluster}_j} x_n = N_j m_j \Leftrightarrow m_j = \frac{1}{N_j} \sum_{x_n \in \text{Cluster}_j} x_n.$$

Từ phân tích trên ta dẫn tới thuật toán K-Means như sau.

k-means Algorithm

Thuật toán k-means

- ▶ Cho tập dữ liệu $\mathbf{X} = \{\mathbf{x}_n\}_{n=1}^N$ và số cụm cần phân chia $0 < k < N$.
- ▶ Khởi tạo: Lấy k điểm dữ liệu khác nhau $c_1, c_2, \dots, c_k$ từ tập $\mathbf{X}$ - là các điểm trung tâm mỗi cụm. Tại bước lặp thứ t :
 - ▶ Gán điểm dữ liệu vào cụm:
 - ▶ Với k tâm cụm từ bước trước, với mỗi điểm dữ liệu $\mathbf{x}_n$, tính các khoảng cách $d_{n,j} = \text{dist}(\mathbf{x}_n, c_j)$ từ $\mathbf{x}_n$ đến tâm cụm hiện tại tại c_j .
 - ▶ Giả sử l là chỉ số cụm có $d_{n,l} = \text{dist}(\mathbf{x}_n, c_l)$ nhỏ nhất.
 - ▶ Gán điểm $\mathbf{x}_n$ vào cụm thứ l , tức cụm có tâm hiện tại là c_l .
 - ▶ Sau thao tác gán, dữ liệu $\mathbf{X}$ được chia vào các cụm $S_1, S_2, \dots, S_k$.
 - ▶ Xác định lại tâm cụm: Tâm cụm c_j sẽ được xác định lại là trung bình cộng các điểm trong cụm S_j đó: $c_j^{\text{new}} := \frac{\sum_{\mathbf{x}_n \in S_j} \mathbf{x}_n}{|S_j|}$. Gán $t = t + 1$ và lặp lại.
- ▶ Thuật toán dừng khi tâm cụm tìm được ở bước $t + 1$ hoàn toàn trùng với tâm cụm tìm được ở bước t .

k-means Algorithm

Một số lưu ý khi thực hiện thuật toán

- ▶ Số cụm k phù hợp nhất: Tùy theo số điểm dữ liệu N . Số cụm k tối ưu thường được chọn bằng cách xét một dãy các giá trị của k và tìm giá trị phù hợp nhất.
- ▶ Chọn tâm cụm ở bước khởi tạo
 - ▶ Không chọn các điểm khởi tạo quá gần nhau.
 - ▶ Chọn điểm c_1 bất kỳ
 - ▶ Chọn c_2 ở xa c_1 nhất có thể (theo khoảng cách Euclide).
 - ▶ Chọn c_3 sao cho $\text{dist}(c_1, c_3) + \text{dist}(c_2, c_3)$ lớn nhất có thể.
 - ▶ Tiếp tục như vậy cho đến tâm cụm chỉ số k .

DBScan Algorithm

DBScan Algorithm

DBScan: Density-Based Spatial Clustering of Applications with Noise.

- ▶ DBSCAN là thuật toán phân cụm dựa trên mật độ điểm, rất phổ biến trong học máy và khai phá dữ liệu.
- ▶ Áp dụng tốt trong trường hợp
 - ▶ Phát hiện các cụm có hình dạng tự do (không chỉ hình cầu/ ellipse như K-Means/GMM).
 - ▶ Xử lý được với điểm dữ liệu ngoại lệ/nhiều (outliers).
- ▶ Tham số chính (siêu tham số)
 - ▶ ϵ (**epsilon**): bán kính lân cận để xét mật độ điểm.
 - ▶ **MinPts**: ngưỡng số lượng điểm tối thiểu trong một vùng bán kính ϵ để vùng đó được coi là vùng đủ mật độ.

DBScan Algorithm

DBScan:

- ▶ Một số khái niệm quan trọng của DBScan
 - ▶ **Điểm lõi (Core Point)**: Nếu có ít nhất **MinPts** điểm nằm trong lân cận bán kính ϵ (kể cả chính nó).
 - ▶ **Điểm biên (Border Point)**: không đủ **MinPts** trong lân cận bán kính ϵ , nhưng thuộc vùng lân cận của một điểm lõi.
 - ▶ **Điểm nhiễu (Noise Point)**: không phải điểm lõi cũng không phải điểm biên.

DBScan Algorithm

► **Bước 1: Xác định các tham số**

- Người dùng chọn giá trị cho ϵ và **MinPts**.
- Đánh dấu tất cả các điểm là chưa thăm (`visited = False`).
- Đặt chỉ số cum hiên tại là $C = 0$.

► **Bước 2: Duyệt qua tất cả các điểm dữ liệu - Với mỗi điểm chưa được phân cụm:**

- ▶ Đánh dấu điểm đã được thăm ($\text{visited} = \text{True}$).
- ▶ Tìm láng giềng của điểm này trong phạm vi lân cận V_ϵ bán kính ϵ của nó.
- ▶ Nếu số lượng láng giềng $\geq \text{MinPts}$, khởi tạo cụm mới ($C = C + 1$) và mở rộng cụm (**Expand Cluster**) từ điểm đó.
- ▶ Nếu số lượng láng giềng $< \text{MinPts}$, đánh dấu là nhiễu tạm thời (có thể sau đó được gán vào cụm khác nếu là điểm biên).

● ● ●

DBScan Algorithm

DBScan Algorithm Pseudo Code:

```
DBSCAN(D, eps, MinPts):  
    C = 0  
    for each unvisited point P in dataset D:  
        mark P as visited  
        NeighborPts = regionQuery(P, eps)  
        if len(NeighborPts) < MinPts:  
            mark P as NOISE  
        else:  
            C = next cluster  
            expandCluster(P, NeighborPts, C, eps, MinPts)
```


DBScan Algorithm

DBScan Algorithm Pseudo Code - expandCluster:

```
expandCluster(P, NeighborPts, C, eps, MinPts):  
    add P to cluster C  
    for each point P1 in NeighborPts:  
        if P1 is not visited:  
            mark P1 as visited  
            NeighborPts1 = regionQuery(P1, eps)  
            if len(NeighborPts1) >= MinPts:  
                NeighborPts = NeighborPts U NeighborPts1  
    if P1 is not yet member of any cluster:  
        add P1 to cluster C
```

DBScan Algorithm

► Ưu điểm

- Tự động xác định số lượng cụm (không cần chỉ định trước như K-Means/GMM).
- Phát hiện tốt các cụm có hình dạng phức tạp.
- Phát hiện nhiễu.

► Nhược điểm

- Khó chọn tham số ϵ và **MinPts** phù hợp.
- Không tốt nếu dữ liệu có mật độ không đồng đều (các cụm có mật độ khác nhau).
- Tính toán khoảng cách cho tất cả các cặp điểm (nên chi phí có thể cao với dữ liệu lớn).

Evaluation metrics of clustering algorithms

Unsupervised Evaluation

2. Davies–Bouldin Index (DBI)

- ▶ **Ý nghĩa:** Đo lường độ tương đồng giữa các cụm. Chỉ số càng nhỏ càng tốt.
- ▶ Công thức: Với số cụm C đã cho:

$$DBI = \frac{1}{C} \sum_{i=1}^C \max_{j \neq i} \left(\frac{\sigma_i + \sigma_j}{d_{ij}} \right) \quad (2)$$

- ▶ σ_i : độ rộng cụm i (trung bình khoảng cách từ điểm trong cụm đến tâm cụm).
- ▶ d_{ij} : khoảng cách giữa tâm cụm i và j .

Supervised Evaluation

1. Adjusted Rand Index (ARI)

- ▶ **Ý nghĩa:** đánh giá sự trùng khớp giữa kết quả phân cụm và nhãn thật, đã hiệu chỉnh xác suất ngẫu nhiên.
- ▶ Công thức: Với số cụm và số phân lớp đã biết:

$$ARI = \frac{RI - \mathbb{E}[RI]}{\max(RI) - \mathbb{E}[RI]} \quad (4)$$

Trong đó

- ▶ RI : Rand Index.
- ▶ $\mathbb{E}[RI]$: kỳ vọng của Rand Index nếu gán nhãn ngẫu nhiên.

Supervised Evaluation

1. ...ARI: RI

- ▶ **Rand Index:** đo mức độ tương đồng giữa cách phân nhóm và nhãn dữ liệu:
 - ▶ một là nhãn phân cụm mô hình sinh ra,
 - ▶ hai là nhãn thật (ground truth).

$$RI = \frac{TP + TN}{TP + TN + FP + FN}$$

Với mỗi cặp điểm (x_m, x_n) có thể xảy ra 04 trường hợp ứng với TP, TN, FP, FN:

Trường hợp	Nhãn Ground Truth	Nhãn Phân Cụm	Ghi chú
TP	cùng nhãn	cùng cụm	Phân đúng cặp giống
TN	khác nhãn	khác cụm	Phân đúng cặp khác
FP	khác nhãn	cùng cụm	Sai, gộp nhầm
FN	cùng nhãn	khác cụm	Sai, chia nhầm

Supervised Evaluation

1. ...ARI: $\mathbb{E}[RI]$

- ▶ **Rand Index (RI)** có thể vẫn cao dù phân cụm rất kém, đặc biệt với trường hợp dữ liệu trong các nhãn mất cân bằng.
- ▶ **Expected Rand Index ($\mathbb{E}[RI]$)**: đại diện cho giá trị Rand Index trung bình mà ta kỳ vọng thu được nếu gán nhãn phân cụm hoàn toàn ngẫu nhiên.
- ▶ Nó là một chuẩn tham chiếu để ta biết: liệu Rand Index của mô hình có thực sự có ý nghĩa, hay chỉ là kết quả ngẫu nhiên. Ví dụ, với một cách phân cụm nào đó mà:
 - ▶ RI tương ứng lớn, nhưng $\mathbb{E}[RI]$ cũng lớn chứng tỏ có phân cụm theo cách ngẫu nhiên bất kỳ khác thì RI cũng có thể lớn, vì vậy cách phân cụm nói trên chưa chắc đã tốt.
 - ▶ RI tương ứng không quá lớn, nhưng $\mathbb{E}[RI]$ nhỏ chứng tỏ cách phân cụm đang có là tốt hơn hẳn những cách khác.

Supervised Evaluation

1. ...ARI: $\mathbb{E}[R]$ Cách tính $\mathbb{E}[R]$: Ký hiệu:

- ▶ Dữ liệu có N điểm.
- ▶ Nhãn thật chia thành C phân lớp: $A_1, A_2, \dots, A_C$.
- ▶ Kết quả phân cụm chia thành K cụm: $B_1, B_2, \dots, B_K$.
- ▶ n_{ij} : số điểm thuộc giao giữa A_i và B_j .
- ▶ $a_i = \sum_{j=1}^K n_{ij}$: số điểm trong phân lớp A_i .
- ▶ $b_j = \sum_{i=1}^C n_{ij}$: số điểm trong cụm B_j .

Với M phần tử, số cách ghép cặp 02 phần tử bất kỳ là $\binom{M}{2} = \frac{M(M-1)}{2}$.

Supervised Evaluation

1. ...ARI: $\mathbb{E}[RI]$ Cách tính $\mathbb{E}[RI]$:

$$\mathbb{E}[RI] = \frac{\sum_i \binom{a_i}{2}}{\binom{N}{2}} \times \frac{\sum_j \binom{b_j}{2}}{\binom{N}{2}} = \frac{\sum_i \binom{a_i}{2} \sum_j \binom{b_j}{2}}{\binom{N}{2}^2} \quad (5)$$

- ▶ Ở đây, ta coi các nhãn được gán ngẫu nhiên nhưng số phần tử trong mỗi cụm là cố định (phân phối hypergeometric) - cụm và lớp phân độc lập.
- ▶ Công thức (5) cho giá trị kỳ vọng của số cặp điểm được phân giống nhau trong cả hai phân lớp A_i phân cụm B_j , với việc phân cụm và phân lớp độc lập.

Supervised Evaluation

1. ...ARI:

Rand Index (RI) có thể tính theo công thức (tự kiểm tra):

$$RI = \frac{\sum_{i,j} \binom{n_{ij}}{2} + \left[\binom{N}{2} - \sum_i \binom{a_i}{2} - \sum_j \binom{b_j}{2} + \sum_{i,j} \binom{n_{ij}}{2} \right]}{\binom{N}{2}}$$

RI không đánh giá được phân cụm là tốt hay không. **Adjusted Rand Index (ARI)** được sử dụng và:

- ▶ $ARI = 1$ khi phân cụm trùng khớp hoàn toàn với nhãn thật.
- ▶ $ARI \approx 0$ khi kết quả phân cụm không tốt hơn ngẫu nhiên.
- ▶ $ARI < 0$ nếu phân cụm tệ hơn cả ngẫu nhiên.

Supervised Evaluation

2. Fowlkes–Mallows Index (FMI)

- ▶ **Ý nghĩa:** Đo lường mức độ tương quan tương tự giữa các cặp điểm được gán cùng cụm với cùng nhãn trong hai phân phối (càng lớn càng tốt).
- ▶ Công thức: Với số cụm và số phân lớp đã biết:

$$FMI = \sqrt{\frac{TP}{TP + FP} \cdot \frac{TP}{TP + FN}} \quad (6)$$

Trong đó

- ▶ *TP*: True Positive (số cặp điểm cùng nhãn và cùng cụm).
- ▶ *FP*: False Positive (số cặp điểm khác nhãn nhưng cùng cụm).
- ▶ *FN*: False Negative (số cặp điểm cùng nhãn nhưng khác cụm).

(Xem lại bảng trong phần tính ARI)

Supervised Evaluation

3. Normalized Mutual Information (NMI)

- ▶ **Ý nghĩa:** Đo lượng thông tin chung giữa hai phân phối của cụm và nhãn (phân cụm và nhãn thật - Giá trị càng lớn càng tốt).
- ▶ Công thức: Với cách cụm U và cách phân lớp V đã cho (tức là $X = \cup_{i=1}^K U_i$ - cụm; $X = \cup_{j=1}^C V_j$ - lớp):

$$NMI(U, V) = \frac{2 \cdot I(U; V)}{H(U) + H(V)} \quad (7)$$

Trong đó

- ▶ $I(U; V)$: mutual information (thông tin đồng thời) giữa cách phân cụm U và cách phân lớp V .
- ▶ $H(U), H(V)$: entropy của dữ liệu theo cách phân cụm U hoặc theo cách phân lớp V .

3. Normalized Mutual Information (NMI)

- ▶ Giá trị của NMI nằm trong khoảng $[0, 1]$:
 - ▶ $NMI = 1$: hai cách phân cụm U và phân lớp V hoàn toàn giống nhau (trùng khớp).
 - ▶ $NMI = 0$: hai cách phân cụm U và phân lớp V độc lập, không có thông tin chung.

Supervised Evaluation

3. ...NMI - Mutual Information:

- ▶ **Ý nghĩa:** Mutual Information đo lượng thông tin hai phân cụm chia sẻ. Nó cho biết phân cụm này giúp giảm độ bất định của phân cụm kia như thế nào.
- ▶ **Công thức:** Cho K là số cụm U_i , C là số phân lớp V_j

$$I(U; V) = \sum_{i=1}^K \sum_{j=1}^C P(i, j) \cdot \log \left(\frac{P(i, j)}{P(i) \cdot P(j)} \right) \quad (8)$$

Trong đó, với N là tổng số điểm dữ liệu:

- ▶ $P(i)$: xác suất 1 điểm thuộc phân cụm U_i : $P(i) := P(U_i) = \frac{|U_i|}{N}$
- ▶ $P(j)$: xác suất 1 điểm thuộc phân lớp V_j : $P(j) := P(V_j) = \frac{|V_j|}{N}$
- ▶ $P(i, j)$: xác suất điểm nằm trong giao giữa $U_i \cap V_j$: $P(i, j) = \frac{|U_i \cap V_j|}{N}$

Supervised Evaluation

Chú ý từ (8), nếu U và V độc lập hoàn toàn thì $I(U; V) = 0$.

3. ...NMI - Entropy $H(U), H(V)$:

- ▶ **Entropy - Ý nghĩa:** Entropy đo độ ngẫu nhiên hoặc bất định của một cách phân cụm (phân lớp).
- ▶ **Công thức:** Giả sử có K cụm U_i và C lớp V_j

$$H(U) = - \sum_{i=1}^K P(U_i) \cdot \log P(U_i); \quad H(V) = - \sum_{j=1}^C P(V_j) \cdot \log P(V_j) \quad (9)$$

Trong đó, với N là tổng số điểm dữ liệu: $P(U_i) = \frac{|U_i|}{N}$; $P(V_j) = \frac{|V_j|}{N}$.